



AgroPredict SN

Simulateur de rendement agricole

Rapport de projet

AgroPredict SN - Simulateur de rendement agricole

Papa Malick NDIAYE

Master 2 Data Science & Génie Logiciel

Université Alioune Diop de Bambey

njaymika@gmail.com

Application en ligne : <https://agropredict-sn.streamlit.app>

Présentation : https://pa-malick.github.io/Agro_Predict-SN/

Juillet 2026

1. Présentation en bref

En une phrase

Un agriculteur répond à cinq questions sur son téléphone, et l'application lui dit combien il va récolter.

Comment ça marche, en trois temps

1. Les données. On part des rendements agricoles réels du Sénégal (FAOSTAT) et de la météo réelle (NASA POWER). Un script assemble tout cela en un tableau : région, culture, engrais, irrigation, et le rendement obtenu.
2. L'apprentissage. Un modèle XGBoost lit ce tableau et apprend les régularités : le riz de Saint-Louis rend plus que le mil de Sédhiou, l'engrais aide un peu. On enregistre ce qu'il a appris dans un fichier.
3. L'application. L'agriculteur choisit sa région, sa culture, sa surface, son engrais et son irrigation. Le modèle calcule, et l'écran affiche deux chiffres : le rendement en tonnes par hectare et la récolte totale en sacs.

Ce n'est pas un modèle qui prédit l'avenir. C'est un simulateur honnête, industrialisé proprement : données assumées, modèle traçable, tests qui protègent réellement.

2. Contexte et problème

L'agriculture fait vivre une grande partie de la population sénégalaise. En début de saison, l'agriculteur décide quoi semer, sur quelle surface, avec ou sans engrais. Il prend cette décision sans repère chiffré.

AgroPredict SN répond à une seule question : pour ma culture, dans ma région, avec mes pratiques, quel rendement puis-je attendre ?

3. Ce que l'application fait et ne fait pas

L'utilisateur renseigne cinq informations qu'il connaît :

- sa région
- sa culture
- sa surface, en hectares
- son niveau d'engrais
- son mode d'irrigation

Il obtient deux chiffres : le rendement attendu, avec une fourchette, et la récolte totale sur sa parcelle, exprimée en sacs de 50 kg.

Ce que l'application ne fait pas, volontairement :

- Elle ne prédit pas une année précise. Elle donne un rendement en conditions normales.
- Elle ne demande pas de données techniques comme le NDVI ou le pH.
- Elle ne remplace pas un conseiller agricole.

4. Les données

Les sources

Source	Ce qu'elle apporte
FAOSTAT	Rendements nationaux réels du Sénégal, par culture, 2000 à 2022
NASA POWER	Météo réelle par région, saison des pluies de juin à octobre
DAPSA	Facteurs de répartition régionale des rendements

Un point important, écrit clairement

Les rendements par parcelle ne sont pas des mesures de terrain. Ils sont obtenus en répartissant les rendements nationaux FAOSTAT entre les régions, puis en ajoutant une variabilité liée aux pratiques. Le modèle apprend donc cette règle de répartition. Ses métriques mesurent sa capacité à la retrouver, pas à prédire un rendement réellement observé.

Ce choix est assumé : il n'existe pas de jeu de données public de rendements parcellaires au Sénégal. La météo, elle, est bien réelle.

5. Le modèle

L'algorithme retenu est XGBoost, une méthode d'arbres de décision renforcés, adaptée aux tableaux de données comme le nôtre.

Deux précautions de méthode

- Le découpage entre entraînement et test est fait par groupe année, région et culture. Des parcelles issues d'une même situation ne se retrouvent pas des deux côtés, ce qui donnerait des scores trop flatteurs.
- Le nombre d'arbres est réglé sur un jeu de validation distinct du jeu de test. Le test reste ainsi vraiment indépendant.

Résultats mesurés

Indicateur	Valeur
Coefficient R ²	0.9441
Erreur RMSE (t/ha)	0.3296
Erreur moyenne MAE (t/ha)	0.1837
Observations	6440
Dont entraînement / test	4120 / 1288
Nombre de variables	64

Ces chiffres sont lus directement dans le modèle entraîné au moment de la génération de ce rapport ; ils ne sont pas recopiés à la main.

6. Architecture technique

Élément	Rôle
streamlit_app.py	Le simulateur, sur un seul écran
pages/1_Le_modele.py	Traçabilité, métriques et limites du modèle
models/train_model.py	Entraînement et découpage par groupe
models/predict.py	Simulation et validation des entrées
utils/referentiel.py	Source unique des valeurs autorisées
data/pipelines/	Récupération NASA POWER et construction du jeu de données
tests/	Critères d'acceptation automatisés

7. Qualité et industrialisation

Chaque exigence du cahier des charges correspond à un test automatique. La chaîne d'intégration continue échoue si l'un d'eux échoue.

Critère	Ce qu'il garantit
CA-1	Toute valeur de l'interface est connue du modèle, sinon erreur explicite

CA-2	Chaque entrée exposée a un effet mesurable et dans le bon sens
CA-3	Le modèle expose sa version, son commit et l'empreinte de ses données
CA-4	Aucune métrique n'est écrite en dur dans le code
CA-5	Les rendements restent dans les plages agronomiques connues
CA-6	La chaîne d'intégration échoue si un critère échoue

Le modèle est traçable : version 2.0.0, commit 33e36b4, empreinte de données ce683000b52f8885. Ces trois éléments suffisent à le reconstruire à l'identique.

L'application est aussi disponible en image Docker, dont la CI vérifie qu'elle démarre correctement.

8. Limites reconnues

- Les rendements sont répartis à partir de statistiques nationales, pas observés.
- Le modèle ne prédit pas une année future.
- Les effets climatiques ne sont pas modélisés ; c'est la principale piste d'évolution.
- Sept régions et cinq cultures seulement.
- Le simulateur donne un ordre de grandeur, il ne remplace pas un conseiller.

9. Conclusion

AgroPredict SN est un outil simple et utile : il transforme des statistiques agricoles en une estimation lisible pour un agriculteur. Sa valeur ne tient pas à un score de précision élevé, mais à sa rigueur : des données dont l'origine est assumée, un modèle traçable, et des tests qui garantissent réellement son comportement.